



## Bloc 5 : Industrialisation d'un algorithme d'apprentissage automatique et automatisation des processus de décision

Get Around : deployment project

**getaround**

[Dépôt Github](#)

# Contexte et besoins du projet

- **Contexte**

- **Getaround** est une plateforme de location de voitures entre particuliers (plus de 5 millions d'utilisateurs et 20 000 véhicules en 2019)
- Chaque location nécessite un check-in et un check-out pour vérifier l'état du véhicule, le carburant et le kilométrage

- **Problème**

- les retours au checkout génèrent des frictions pour les conducteurs suivants
- impactent les locations suivantes (annulations) et le CA

# Objectifs et périmètre du projet

- **Objectif principal**

- Getaround souhaite réduire les frictions opérationnelles tout en préservant les revenus des propriétaires et de la plateforme
- **Questions :**
  - quel délai minimum imposer entre 2 locations et à quel coût?
  - comment évaluer au mieux le prix de location d'un véhicule

- **Périmètre**

- Phase 1 : Mieux définir le prix d'une location pour un véhicule
- Phase 2 : Définition du seuil minimal de délai entre 2 réservations
  - Délai applicable à tous les véhicules en check-in de type "Mobile", ou uniquement les véhicules "GetAround Connect"?
  - Analyser l'impact du délai sur le CA et le nombre de locations problématiques concernées

# **Phase 1 : Pricing des locations**

## **Modèle de ML**

# EDA sur le Dataset Pricing

- **Chiffres clé**

- **4383 véhicules**, pas de valeurs null
- 2 lignes à exclure (mileage<0 et une avec engine\_power=0)

- **Features**

- Numériques: mileage, engine\_power
- Catégorielles :
  - model\_key : 28 marques
  - fuel : 4 types
  - car\_type : 8 catégories
  - paint\_color : 10 couleurs
- Booléennes : GPS, clim, boite auto, GetAround connect, régulateur, pneu hiver, parking privé

# EDA : observations et analyses

- **Corrélations des variables avec le prix de location par jour**
  - forte : engine\_power (pearson  $\sim +0.6$ )
  - assez forte : mileage, automatic\_car (pearson  $\sim +/ -0.4$ )
  - modérée :
    - has\_getaround\_connect, has\_gps (pt-bis.  $\sim +0.3$ )
    - model\_key : modérée (eta2  $\sim +0.3$ )
  - **faible**
    - winter\_tires : faible  $+0.02$
    - paint\_color : faible  $+0.01$
    - fuel : faible  $+0.01$

**Pour le modèle on pourra tester en enlevant les features à faible impact**

# Entraînement modèles

- Entraînement de plusieurs modèles et plusieurs variantes

| Modèle                          | Dataset              | R2            | MAE (€/j)    | RMSE (€/j)   |
|---------------------------------|----------------------|---------------|--------------|--------------|
| <b>XGBoost + GridSearchCV</b>   | <b>4841 (full)</b>   | <b>0.7646</b> | <b>10.39</b> | <b>16.05</b> |
| <b>LR baseline</b>              | <b>4841 (full)</b>   | <b>0.7060</b> | <b>12.11</b> | <b>17.94</b> |
| LR sans paint/fuel/winter_tires | 4841 (full)          | 0.6820        | 12.48        | 18.65        |
| Ridge + règle $3\sigma$         | sans outliers (4749) | 0.6317        | 12.77        | 19.06        |
| Lasso + règle $3\sigma$         | sans outliers (4749) | 0.6277        | 12.80        | 19.17        |
| LR + règle $3\sigma$            | sans outliers (4749) | 0.6246        | 12.88        | 19.24        |


## **Phase 2 : Analyse et évaluation des retards**



# Analyse des retards à partir du dataset des locations (1)

- **767 locations A en retard avec une location suivante B connue**
- **182 dont ayant causé un problème à B ( $\text{delay\_A} \geq \text{B\_time\_delta}$ ) soit 23.7%**


Retards de A ayant impacté B — connect vs mobile



- **Répartition des types de check-in pour ces 182 locations**
  - **72.5% en mobile**
  - **27.5% en connect**

# Analyse des retards à partir du dataset des locations (2)

Délai nécessaire pour couvrir X% des retards impactants (connect vs mobile)




- retards connect plus courts et plus concentrés (écart-type faible)
- retards mobile avec moyenne et une variance nettement plus élevées
- médianes proches
- majorité des conflits <1h, mais la "queue" de distribution mobile est plus longue

**Cela justifie de définir un délai minimum différencié selon le type de check-in**

# Analyse des retards à partir du dataset des locations (2)

Délai nécessaire pour couvrir X% des retards impactants (connect vs mobile)

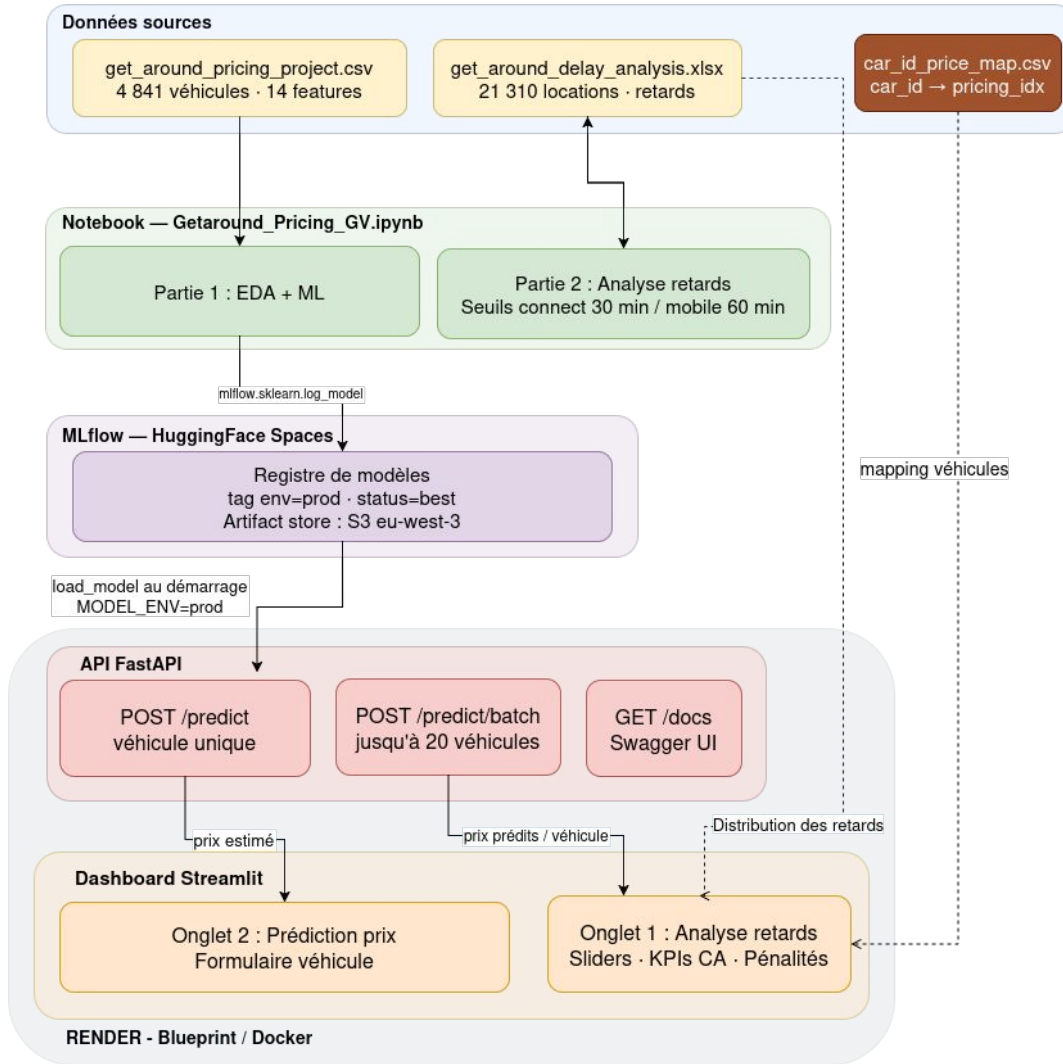


- retards connect plus courts et plus concentrés (écart-type faible)
- retards mobile avec moyenne et une variance nettement plus élevées
- médianes proches
- majorité des conflits <1h, mais la "queue" de distribution mobile est plus longue

**Cela justifie de définir un délai minimum différencié selon le type de check-in**

## **Phase 2 : Automatisation et Industrialisation**

# Architecture du pipeline



# Architecture du pipeline

- pour calculer un CA plus réaliste (au lieu d'utiliser la moyenne du prix de location) -> création d'un fichier d'association entre le car\_id des locations et l'idx du véhicule du fichier pricing
- prédiction du prix de chaque véhicule monté en cache au chargement du dashboard
- data analyse du retard montées en cache également dans le dashboard

# Démonstration des déploiements (Hugging Face et Render)

- Sur Hugging Face
  - serveur MLFlow 3.7.  
<https://gvriel-mlflow37.hf.space/#/>
- Sur Render :
  - API predict (documentation swagger)  
<https://getaround-api-hmuc.onrender.com/docs/>
  - Dashboard Streamlit  
<https://getaround-dashboard.onrender.com>

NB : Render plan gratuit => cold start après 15 min d'inactivité (~30–60 s de rechargement du modèle depuis S3)

# Conclusions



# Conclusions

- Sur

# Jedha - Data Science Fullstack

Certification CDSD (Concepteur développeur en science des données)

---



Questions ?